

PEC2 - Análisis de Datos Ómicos

Lucas Moratilla Lapeña

2026-05-05

Introducción

El análisis de datos ómicos mediante RNA-seq representa una de las herramientas más potentes en la actualidad, permitiendo caracterizar de forma global el perfil de expresión génica de un tejido. Su aplicación en el estudio del cáncer ha permitido identificar genes y rutas transcripcionales implicadas en la transformación maligna, progresión tumoral y la investigación de nuevas dianas terapéuticas.

Para el correcto análisis de los datos RNA-seq es necesario realizar una serie de pasos metodológicos para garantizar la adecuada calidad del mismo. El uso de objetos SummarizedExperiment integrados en el paquete Bioconductor junto con las librerías limma, edgeR o clusterProfiles permite que la complejidad de estos procesos se organice de manera más estructurada. Estos objetos integran los datos de expresión génica junto con sus metadatos, facilitando el análisis exploratorio y preprocesado de los datos, pasos indispensables antes del análisis de expresión diferencial. El entorno de Bioconductor a su vez permite obtener los genes diferencialmente expresados entre tejidos así como la realización de un análisis de sobrerepresentación que permita explicar la significancia biológica de los resultados.

En este ejercicio se realizará un análisis de expresión diferencial a partir de datos de RNA-seq del estudio GSE50760. Este estudio contiene datos de cáncer colorrectal con un diseño apareado, donde encontramos 3 muestras de tejido por paciente (normal, primary_tumor y liver_metastasis). El objetivo principal será identificar genes diferencialmente expresados entre tumor primario y tejido normal así como explorar su significación biológica mediante análisis de sobrerepresentación.

Descripción de los datos

La estructura inicial de nuestro objeto SummarizedExperiment (“se”) recoge la información de 54 muestras de tejido de 18 pacientes con cáncer colorrectal. De cada paciente se recogió una muestra de tejido normal, tumor primario y metástasis hepática, apareada de dicha manera a nivel experimental, constituyendo así el número total de 54 muestras. El objeto “se” recoge a su vez la información de 39376 genes estudiados en estas 54 muestras. En el apartado assay (ensayos) nuestro objeto recoge los datos counts, logCPM, TPM y FKPM, a su vez el apartado colData presenta los datos de 10 variables (geo_accession, sample_title, source_name, characteristics_1, characteristics_2, sample_name, patient_id, condition, sample_type, pair_group) y finalmente rowData presente los datos de 7 variables (gene_id, gene_symbol, description, gene_type, chromosome, map_location, entrez_id, has_entrez).

Subconjunto de datos analizados

Para la realización del análisis de expresión génica se usó un subconjunto de datos del objeto original, constituido por 30 muestras de 10 pacientes. Los pacientes seleccionados para este subconjunto de datos fueron: 12, 13, 19, 20, 21, 22, 3, 5, 7 y 8. Tras la selección se mantuvo la estructura de los datos apareados, teniendo cada paciente 1 muestra de cada tejido.

Análisis exploratorio

El análisis exploratorio de la expresión génica (Figura 1) mostró distribuciones de logCPM comparables entre todas las muestras en los boxplots que se situaron en rangos similares, lo que indica la ausencia de muestras atípicas. No se observaron tampoco diferencias sistemáticas entre los tres tipos de tejido estudiados (normal, primary_tumor y liver_metastasis) a nivel de distribución de expresión génica global, aunque las muestras de metástasis hepática muestran una leve variabilidad más apreciable respecto al resto de muestras.




Figure 1: Expresión génica en función del tipo de muestra obtenida

Se realizó un análisis de componentes principales (PCA) cuyos resultados se muestran en la Figura 2. Las dos primeras componentes explican el 33,1% de la varianza total (PC1: 17,6%, PC2: 15,5%). Se observa una separación parcial por condición (Figura 2B) donde las muestras de tejido normal forman un grupo compacto y bien diferenciado, mientras que las muestras de tumor primario y metástasis hepática tienden a dispersarse hacia valores negativos en PC1. No obstante, las elipses de las tres condiciones se solapan considerablemente, lo que sugiere que existe variabilidad adicional no capturada por las dos primeras componentes. El gráfico por paciente (Figura 2C) muestra un efecto de paciente leve: las muestras del mismo paciente no siempre se agrupan entre sí, lo que indica que la condición explica parte de la variabilidad. Destaca el paciente AMC_19, cuya muestra de metástasis hepática se encuentra claramente alejada del resto, siendo la muestra más atípica del conjunto.




Figure 2: PCA exploratorio

Preprocesado de los datos

Se realizó un preprocesado de los datos previamente identificando aquellos genes cuya expresión fuera CPM >1 en al menos 5 muestras, los cuáles formarán parte del análisis final. A su vez posteriormente se procedió a la normalización de los datos de la expresión de RNA-seq tras el filtrado.

Previamente al filtrado nuestro objeto `se_sub` contaba con 39376 genes, sin embargo, tras la aplicación de los criterios expuestos se eliminaron 20993 genes, permaneciendo un total de 18383 genes para el análisis final. Esto eliminó el 53% de los genes iniciales con baja expresión que no aportarían información relevante al informe final. Para la normalización de los datos se creó un objeto `DGEList` a partir de los datos filtrados. Se utilizó la función `TMM` para dicha normalización, usada para eliminar sesgos técnicos en datos de expresión RNA-seq. Este tipo de normalización es adecuada porque corrige las diferencias en la composición de las librerías entre muestras: genera un conjunto de factores de normalización, donde el producto de estos factores y los tamaños de librería definen el tamaño efectivo de la biblioteca. Para ello se utilizó la función `calcNormFactors`. Los datos resultantes de la normalización se reflejan en la Figura 3.




Figure 3: Expresión génica en función del tipo de muestra obtenida tras la normalización

Modelo y diseño experimental

El modelo y diseño experimental del estudio tomo nuestro objeto tras la filtración y normalización del mismo para la construcción del modelo experimental en forma $\sim$ patient_id+condition

Tras la configuración inicial según el modelo descrito previamente, la matriz de diseño es la siguiente:

Table 1: Matriz de diseño

	(Intercept)	AMC_3	AMC_5	AMC_7	AMC_8	AMC_12	AMC_13	AMC_19	AMC_20	AMC_21	AMC_22	condition	primary_tumor
primary_colorectal_cancer_AMC_3-1		0	0	0	0	1	0	0	0				1
primary_colorectal_cancer_AMC_5-1		0	0	0	0	0	1	0	0				1
primary_colorectal_cancer_AMC_7-1		0	0	0	0	0	0	1	0				1
primary_colorectal_cancer_AMC_8-1		0	0	0	0	0	0	0	1				1
primary_colorectal_cancer_AMC_12-1		0	0	0	0	0	0	0	0				1
primary_colorectal_cancer_AMC_13-1		0	0	0	0	0	0	0	0				1
primary_colorectal_cancer_AMC_19-1		1	0	0	0	0	0	0	0				1
primary_colorectal_cancer_AMC_20-1		0	1	0	0	0	0	0	0				1
primary_colorectal_cancer_AMC_21-1		0	0	1	0	0	0	0	0				1
primary_colorectal_cancer_AMC_22-1		0	0	0	1	0	0	0	0				1

	(Intercept)	AMC_3	AMC_5	AMC_7	AMC_8	AMC_12	AMC_13	AMC_19	AMC_20	AMC_21	AMC_22	condition	primary_tumor
normal_colon_AMC_3-2	1	0	0	0	0	0	1	0	0	0			0
normal_colon_AMC_5-2	1	0	0	0	0	0	0	1	0	0			0
normal_colon_AMC_7-2	1	0	0	0	0	0	0	0	1	0			0
normal_colon_AMC_8-2	1	0	0	0	0	0	0	0	0	1			0
normal_colon_AMC_12-2	1	0	0	0	0	0	0	0	0	0			0
normal_colon_AMC_13-2	1	1	0	0	0	0	0	0	0	0			0
normal_colon_AMC_19-2	1	0	1	0	0	0	0	0	0	0			0
normal_colon_AMC_20-2	1	0	0	1	0	0	0	0	0	0			0
normal_colon_AMC_21-2	1	0	0	0	1	0	0	0	0	0			0
normal_colon_AMC_22-2	1	0	0	0	0	1	0	0	0	0			0

Y la matriz de contrastes:

Table 2: Matriz de contrastes

	primary_vs_normal
Intercept	0
AMC_13	0
AMC_19	0
AMC_20	0
AMC_21	0
AMC_22	0
AMC_3	0
AMC_5	0
AMC_7	0
AMC_8	0
conditionprimary_tumor	1

Dentro de esta matriz de diseño el término patient_id en la matriz de diseño genera una columna por cada paciente (excepto el de referencia, que en este caso es AMC_12). Cada columna indica con un 1 qué muestras pertenecen a ese paciente. De esta forma, el modelo puede estimar cuánto se desvía la expresión génica de cada paciente respecto al paciente de referencia (AMC_12), descontando esa diferencia antes de comparar tumor primario vs normal. Esto permite asegurar que las diferencias que encontremos sean debidas a la condición y no a la variabilidad de la expresión génica entre individuos.

Es importante remarcar que el estudio de las muestras no puede tratarse de manera independiente al ser un diseño apareado, ya que las muestras de cada paciente tienen correlación entre sí, ya que la expresión génica de un paciente a otro podría tener variabilidad debido a multiplicidad de factores relacionados con el propio individuo. Si tratásemos las muestras de manera independiente, ignoraríamos la presencia la propia variabilidad individual produciendo un sesgo al análisis final, reduciendo la potencia estadística para detectar genes diferencialmente expresados.

Expresión diferencial

El análisis de genes diferencialmente expresados se llevó a cabo con el análisis lineal de la matriz de contrastes. Se filtraron aquellos genes cuyo p valor estaba por debajo del nivel de significancia 0.05 y cuyo $|\log FC|$ era >2 .

En total se identificaron 720 genes diferencialmente expresados, de los cuales 325 están sobreexpresados y 395 infraexpresados en tumor primario respecto a tejido normal. Los genes que obtuvieron una mayor expresión diferencial figuran en la Tabla 3. El gen más significativo fue el 144501, con un logFC de 5.63 y un FDR de 0.00135. El resumen del análisis de expresión diferencial se muestra en la Figura 4. En el volcano plot se representan todos los genes analizados, destacando en azul los 10 genes más significativos. Las líneas discontinuas marcan los umbrales establecidos: $|\log 2FC| > 2$ (líneas verticales rojas) y $FDR < 0.05$ (línea horizontal azul).

Table 3: Top 10 genes diferencialmente expresados ordenados por FDR

	logFC	AveExpr	t	P.Value	adj.P.Val	B
144501	5.6266	0.0174	11.2105	0	0.0014	7.1040
1301	5.5343	1.4247	8.6090	0	0.0043	5.5567
100132406	-0.9411	4.8359	-8.4496	0	0.0043	5.5163
1001	4.8346	2.0406	8.4719	0	0.0043	5.5144
3624	5.2220	1.4799	8.3234	0	0.0043	5.2110
1469	5.6973	0.0405	8.6149	0	0.0043	5.0183
864	-1.2275	3.8115	-8.0006	0	0.0043	4.9743
7535	-1.4895	3.4490	-7.9727	0	0.0043	4.9524
3683	-1.4860	4.5086	-7.9628	0	0.0043	4.8982
101060226	-0.8808	4.8265	-7.8934	0	0.0043	4.7859




Figure 4: Volcano plot

Al analizar la proporción de genes infra y sobreexpresados objetivamos una mayor cantidad de genes infraexpresados, esto podría sugerir que la transformación tumoral en el cáncer colorrectal se asocia en mayor medida a una pérdida de la expresión génica respecto al tejido normal, con una posible relación en el silenciamiento de genes supresores de tumores. Este análisis será explotado en mayor profundidad en el análisis de significación biológica.

Análisis de significación biológica (ORA)

Para el análisis de enriquecimiento se usará `entrez_id` ya que `enrichGO` utilizará este tipo de notación. Puede usarse a su vez `gene_id` ya que coincide con `entrez_id` en nuestro caso. Entre los genes diferencialmente expresados y seleccionados con los criterios impuestos previamente encontramos que todos cuentan con un `entrez_id` válido, sin necesidad de eliminar ninguno para el análisis.

El análisis de sobrerrepresentación incluyó un total de 325 genes sobreexpresados con un total de 87 términos GO-BP significativos entre los que encontramos los siguientes 10 mas relevantes, según se refleja en la Tabla 4.

Table 4: Top 10 términos GO-BP significativos en genes sobreexpresados

	Description	GeneRatio	p.adjust	Count
GO: 0030198	extracellular matrix organization	23/229	0e+00	23
GO: 0043062	extracellular structure organization	23/229	0e+00	23
GO: 0045229	external encapsulating structure organization	23/229	0e+00	23
GO: 0043588	skin development	18/229	0e+00	18
GO: 0030574	collagen catabolic process	8/229	1e-04	8
GO: 0022617	extracellular matrix disassembly	9/229	2e-04	9
GO: 0032963	collagen metabolic process	11/229	2e-04	11
GO: 0061844	antimicrobial humoral immune response mediated by antimicrobial peptide	10/229	3e-04	10
GO: 0030216	keratinocyte differentiation	11/229	4e-04	11
GO: 0002009	morphogenesis of an epithelium	23/229	4e-04	23

Entre los 87 términos GO-BP significativos sobreexpresados en el tejido tumoral primario frente al normal, podemos objetivar que los más enriquecidos se organizan en torno a 3 procesos (Figura 5) que son: remodelación y estructuración de la matriz extracelular, diferenciación de células epiteliales y metabolismo del colágeno.

En cuanto al primero (extracellular matrix organization, extracellular structure organization, external encapsulating structure organization, extracellular matrix disassembly) presenta los gene ratio más elevados (0,10), lo que indica que 23 de los 229 genes sobreexpresados con anotación GO están implicados en estos procesos. Esta alteración de las rutas transcripcionales en la remodelación y organización de la matriz extracelular está en línea con lo esperable en el cáncer colorrectal, donde la alteración de estos procesos celulares favorece la invasión y la presencia de metástasis a distancia.

Otro proceso en línea con el anterior es la alteración de los procesos relacionados con el metabolismo del colágeno. Esta alteración permite favorecer la invasión tumoral a través de la activación de genes relacionados con metaloproteasas, que degradan el colágeno circundante y la matriz extracelular, así como la activación de genes de síntesis del colágeno para dar soporte al nuevo estroma tumoral.

Finalmente dentro de los mecanismos del desarrollo del cáncer colorrectal también cobraría importancia la alteración de la diferenciación epitelial debido a la transformación celular del epitelio propio de la mucosa intestinal en línea con la transformación maligna celular.




Figure 5: Dotplot.ORA: Genes sobreexpresados en tumor primario

ORA de genes infraexpresados en tumor y comparación con ORA de genes sobreexpresados

El análisis de sobrerepresentación incluyó un total de 395 genes sobreexpresados con un total de 14 términos GO-BP significativos entre los que encontramos los siguientes, según se refleja en la Tabla 5.

Table 5: Top 10 términos GO-BP significativos en genes infraexpresados

Description	GeneRatio	p.adjust	Count
GO: immunoglobulin mediated immune response 0016064	45/298	0.0000	45
GO: B cell mediated immunity 0019724	45/298	0.0000	45
GO: leukocyte mediated immunity 0002443	55/298	0.0000	55
GO: lymphocyte mediated immunity 0002449	49/298	0.0000	49
GO: adaptive immune response based on somatic recombination of immune 0002460 receptors built from immunoglobulin superfamily domains	49/298	0.0000	49
GO: B cell receptor signaling pathway 0050853	12/298	0.0000	12

	Description	GeneRatio	p.adjust	Count
GO: 0015698	inorganic anion transport	13/298	0.0008	13
GO: 0006821	chloride transport	11/298	0.0009	11
GO: 0050851	antigen receptor-mediated signaling pathway	16/298	0.0018	16
GO: 0006820	monoatomic anion transport	12/298	0.0047	12

Si comparamos los resultados con los genes sobreexpresados en el tejido tumoral (87 términos GO-BP), los genes infraexpresados presentan únicamente 14 términos GO-BP significativos, pero con GeneRatios más elevados (0.15-0.18), mayor significación estadística y un mayor número de genes por término (Figura 6).

Los términos enriquecidos giran en torno a la función inmune: leukocyte mediated immunity, lymphocyte mediated immunity, B cell mediated immunity e immunoglobulin mediated immune response, entre otros. Este silenciamiento de genes relacionados con la respuesta inmune cobra especial sentido biológico si consideramos los mecanismos de eliminación tumoral: las células tumorales presentan antígenos en su superficie a través del MHC-I, que son reconocidos por linfocitos T CD8+ citotóxicos para su eliminación. La pérdida de expresión de genes implicados en estos procesos representa por tanto un mecanismo de evasión inmune tumoral, que permitiría a las células tumorales escapar de la vigilancia inmunológica y progresar.




Figure 6: Figura 6. Dotplot. ORA: Genes infraexpresados en tumor primario

La comparación entre ambos análisis de sobrerepresentación revela perfiles biológicos diferenciados. Los genes sobreexpresados en el tumor primario se asocian principalmente a procesos de remodelación de la matriz extracelular y metabolismo del colágeno, reflejando la activación de mecanismos de invasión tumoral. Por el contrario, los genes infraexpresados se asocian a procesos de respuesta inmune, constituyendo un mecanismo de evasión inmune tumoral que permite la progresión e invasión del tumor.

En conjunto, estos resultados son coherentes con el mecanismo tumoral en cáncer colorrectal en el que el tumor activa simultáneamente mecanismos de invasión tisular (sobreexpresión de genes de remodelación de matriz) y de evasión inmune (infraexpresión de genes de respuesta inmune), dos eventos clave en la transformación maligna y la progresión hacia estadios avanzados.

Discusión

El análisis de expresión diferencial basado en datos de RNA-seq del estudio GSE50760 ha permitido identificar alteraciones transcriptómicas relevantes en el cáncer colorrectal primario respecto al tejido colónico normal donde la sobreexpresión de rutas relacionadas con la remodelación de la matriz extracelular, el metabolismo del colágeno y la alteración de la diferenciación epitelial, así como la infraexpresión de genes relacionados con la respuesta inmune, parecen jugar un papel relevante en el desarrollo y progresión en este tipo de tumores.

El análisis exploratorio inicial sobre la totalidad de los genes identificados (39376 genes) mostró una separación entre muestras tumorales y normales en el análisis de componente principales, lo que sugiere la existencia de un perfil transcripcional diferenciado entre ambos tejidos. Tras el preprocesado de los datos y eliminación de aquellos genes cuyo perfil de expresión se encontraba por debajo de CPM < 1, el análisis de expresión diferencial (FDR < 0,05 y $|\log_2FC| > 2$) identificó 720 genes diferencialmente expresados, 325 sobreexpresados y 395 infraexpresados en el tejido tumoral primario. La significación biológica de estos genes cobra especial relevancia a la hora de analizarlos por separados. La sobreexpresión de genes relacionados con mecanismos de remodelación del ambiente celular permitiría a las células del tumor aumentar la capacidad de invasión tisular y crecimiento tumoral favorecido por la creación de este microambiente específico. Por otro lado, la infraexpresión de genes relacionados con la respuesta inmune tumoral, es si cabe, aún mas relevante con el silenciamiento de este tipo de genes como mecanismo de escape a la respuesta del individuo frente a este tipo de células, permitiendo la progresión tumoral.

Este estudio presenta fortalezas y limitaciones que debemos remarcar. Entre las primeras destaca el diseño apareado, que al comparar cada paciente consigo mismo elimina la variabilidad interindividual a la hora del análisis transcripcional. Como principal limitación, el tamaño muestral reducido (10 pacientes) puede comprometer la potencia estadística y la generalización de los resultados hacia la población general.

Conclusión

El análisis transcriptómico del cáncer colorrectal primario ha permitido identificar varios mecanismos moleculares clave en el desarrollo tumoral: la activación de procesos de remodelación de la matriz extracelular y del metabolismo del colágeno, favoreciendo la invasión tisular, y la supresión de la respuesta inmune adaptativa como mecanismo de evasión tumoral. Ambos hallazgos son coherentes con los mecanismos de progresión descritos en la literatura para el cáncer colorrectal y constituyen potenciales dianas terapéuticas de interés para futuras investigaciones.

Apéndices

```
if (!requireNamespace("knitr", quietly = TRUE))
  install.packages("knitr")
```

```

if (!requireNamespace("BiocManager", quietly = TRUE))
  install.packages("BiocManager")

if (!requireNamespace("SummarizedExperiment", quietly = TRUE))
  BiocManager::install("SummarizedExperiment")

if (!requireNamespace("edgeR", quietly = TRUE))
  BiocManager::install("edgeR")

if (!requireNamespace("limma", quietly = TRUE))
  BiocManager::install("limma")

if (!requireNamespace("POMA", quietly = TRUE))
  BiocManager::install("POMA")

if (!requireNamespace("FactoMineR", quietly = TRUE))
  install.packages("FactoMineR")

if (!requireNamespace("factoextra", quietly = TRUE))
  install.packages("factoextra")

if (!requireNamespace("umap", quietly = TRUE))
  install.packages("umap")

if (!requireNamespace("clusterProfiler", quietly = TRUE))
  BiocManager::install("clusterProfiler")

if (!requireNamespace("org.Hs.eg.db", quietly = TRUE))
  BiocManager::install("org.Hs.eg.db")

library(knitr)
library(SummarizedExperiment)
library(edgeR)
library(limma)
library(ggplot2)
library(POMA)
library(FactoMineR)
library(factoextra)
library(umap)
library(patchwork)
library(clusterProfiler)
library(org.Hs.eg.db)

knitr::opts_chunk$set(fig.width = 7, fig.height = 5)
#cargamos los datos desde el repositorio github
load("PEC2_GSE50760_colorectal_SE.Rda")
#exploramos las dimensiones de se para ver muestras y genes
dim(se)
#exploramos assay
assayNames(se)
#exploramos colData
colnames(colData(se))
#exploramos rowData

```

```

colnames(rowData(se))
#exploramos la variable condition para verificar el numero de muestras
table(se$condition)
#para verificar la estructura apareada del diseño experimental,
#debemos enfrentar a cada paciente con condition
table(se$patient_id, se$condition)
#plantamos la semilla con las ultimas 4 cifras del DNI
#para seleccionar los pacientes
myseed <- sum(utf8ToInt("6056"))
set.seed(myseed)
patients <- unique(se$patient_id)
selected_patients <- sample(patients, 10)
se_sub <- se[, se$patient_id %in% selected_patients]
se_sub
#realizamos la comprobación del diseño apareado
#y la selección de pacientes
table(se_sub$patient_id, se_sub$condition)
#debemos crear un nuevo SummarizedExperiment para usar en vez de los
#datos crudos, los datos transformados logCPM y así
#trabajar con POMA
se_sub_log <- se_sub
assay(se_sub_log, "counts") <- assay(se_sub, "logCPM")

PomaBoxplots(se_sub_log, x = "samples", outcome = "condition")
#trasponemos la matriz para hacer PCA
se_sub_t <- t(assay(se_sub_log))
#hacemos PCA
pca <- PCA(se_sub_t, ncp = 5, graph = FALSE)

# Graficamos PCA coloreado por condition
ind_condition <- fviz_pca_ind(pca, label = "none",
                             col.ind = se_sub_log$condition,
                             addEllipses = TRUE,
                             legend.title = "Condición") +
  labs(title = "A. Condición")

#Graficamos PCA por paciente
ind_patient <- fviz_pca_ind(pca, label = "none",
                           col.ind = se_sub$patient_id,
                           legend.title = "Paciente") +
  labs(title = "B. Paciente")

ind_condition | ind_patient
#extraemos la matriz de counts
counts_matrix <- assay(se_sub, "counts")
#calculamos CPM con la función cpm() de edgeR
cpm_matrix <- cpm(counts_matrix)
#seleccionamos los genes con cpm > 1 en al menos 5 muestras
thresh <- cpm_matrix > 1
keep <- rowSums(thresh) >= 5
#comparamos antes y después
dim(counts_matrix)
dim(counts_matrix[keep, ])

```

```

#aplicamos el filtro al objeto SummarizedExperiment
se_sub_filt <- se_sub[keep, ]
#comprobamos que se haya aplicado correctamente
dim(se_sub_filt)
#creamos el objeto DGEList a partir de los datos filtrados previamente
#y agrupados por la variable condition
dgeObj <- DGEList(counts = assay(se_sub_filt, "counts"), group = se_sub_filt$condition)
#comprobamos que contiene dgeObj
names(dgeObj)
#asi como su contenido samples
dgeObj$samples
#aplicamos la normalizacion
dgeObj_norm <- calcNormFactors(dgeObj, method = "TMM")
#obtenemos el logaritmo de los counts
logcounts_norm <- cpm(dgeObj_norm, log=TRUE)
#dibujamos el boxplot con los datos normalizados
boxplot(logcounts_norm, ylab="Log2-CPM", las=2, xlab="", cex.axis=0.7, main="Boxplots of logCPMs (normal.
# Let's add a blue horizontal line that corresponds to the median logCPM
abline(h=median(logcounts_norm), col="blue")
#seleccionamos unicamente las muestras normal y primary tumor
#de nuestro objeto filtrado previamente
se_pn <- se_sub_filt[, se_sub_filt$condition %in% c("normal", "primary_tumor")]
se_pn$condition <- droplevels(se_pn$condition)
se_pn$patient_id <- factor(se_pn$patient_id)
#comprobamos la dimensionalidad del objeto
dim(se_pn)
table(se_pn$condition)
#creamos otro objeto DGEList para la normalización de este subset
dge_pn <- DGEList(counts = assay(se_pn, "counts"),
                  group = se_pn$condition)
#aplicamos normalización TMM
dge_pn <- calcNormFactors(dge_pn, method = "TMM")
#definimos los factores
group <- paste(se_pn$patient_id, se_pn$condition, sep = ".")
#construimos la matriz de diseño con patient_id y condition
design <- model.matrix(~ patient_id + condition, data = colData(se_pn))
colnames(design) <- gsub("patient_id", "", colnames(design))
rownames(design) <- colnames(se_pn)
kable(design, caption = "Matriz de diseño")
cont.matrix <- makeContrasts(primary_vs_normal = conditionprimary_tumor, levels = design)

kable(cont.matrix, caption = "Matriz de contrastes")
#transformamos el objeto DGEList con voom
#para poder analizarlo con limma
voomObj <- voom(dge_pn, design)
#ajustamos el modelo lineal
fit <- lmFit(voomObj)
#aplicamos la matriz de contrastes
fit.cont <- contrasts.fit(fit, cont.matrix)
#regularizamos la estimación del error con eBayes
fit.cont <- eBayes(fit.cont)
#con decideTests aplicamos los criterios
summa.fit <- decideTests(fit.cont, p.value = 0.05, lfc = 2)

```

```

summary(summa.fit)
#extraemos todos los resultados con topTable
results <- topTable(fit.cont, coef = "primary_vs_normal", number = nrow(fit.cont))
kable(head(results, 10), caption = "Top 10 genes diferencialmente expresados ordenados por FDR", digits = 4)
volcanoplot(fit.cont, coef = "primary_vs_normal", highlight = 10,
            names = rownames(fit.cont))

# Líneas de los umbrales
abline(v = c(-2, 2), col = "red", lty = 2)
abline(h = -log10(0.05), col = "blue", lty = 2)
#exploramos rowData para ver que notaciones tenemos disponibles
colnames(rowData(se_pn))
head(rowData(se_pn))
#convertimos rowData en un dataframe para la extraccion correcta de entrez_id y has_entrez
rowData <- as.data.frame(rowData(se_pn))
#extraemos los ids del objeto summafit que son diferentes de 0
deg <- rownames(summa.fit)[summa.fit[, "primary_vs_normal"] != 0]
#realizamos una tabla TRUE/FALSE para comprobar los ids que tienen entrez
table(rowData$has_entrez[rowData$gene_id %in% deg])
#desde el objeto topTable "results" vamos a seleccionar los genes
#sobreexpresados que cumplen los criterios
#seleccionamos los nombres de las filas
allEntrezs <- rownames(results)
#establecemos los criterios de subset
selectedEntrezsUP <- rownames(subset(results, (logFC>2) & (adj.P.Val < 0.05)))
#comprobamos la seleccion correcta
length(selectedEntrezsUP)
#realizamos el analisis con enrichGO
ego <- enrichGO(gene = selectedEntrezsUP,
                universe = allEntrezs,
                keyType = "ENTREZID",
                #tomamos la base de datos del humano
                OrgDb = org.Hs.eg.db,
                #tomamos con ontologia el Biological Process
                ont = "BP",
                #ajustamos las comparaciones multiples
                pAdjustMethod = "BH",
                qvalueCutoff = 0.05,
                readable = TRUE)

head(ego)
#vemos cuantos terminos GO-BP han salido significativos
nrow(ego)
#realizamos la tabla convirtiendo a dataframe ego y añadimos las categorías
#que queremos que aparezcan
top_go <- as.data.frame(ego)[1:10, c("Description", "GeneRatio", "p.adjust", "Count")]
kable(top_go, caption = "Top 10 términos GO-BP significativos en genes sobreexpresados", digits = 4)
dotplot(ego, showCategory = 10, font.size=6)
#establecemos los criterios de subset de infraexpresados
selectedEntrezsDOWN <- rownames(subset(results, (logFC < -2) & (adj.P.Val < 0.05)))
length(selectedEntrezsDOWN)
#realizamos el analisis con enrichGO para genes infraexpresados
egodown <- enrichGO(gene = selectedEntrezsDOWN,
                    universe = allEntrezs,
                    keyType = "ENTREZID",

```

```

#tomamos la base de datos del humano
OrgDb = org.Hs.eg.db,
#tomamos con ontologia el Biological Process
ont = "BP",
#ajustamos las comparaciones multiples
pAdjustMethod = "BH",
qvalueCutoff = 0.05,
readable = TRUE)

head(egodown)
#vemos cuantos terminos GO-BP han salido significativos
nrow(egodown)
#realizamos la tabla convirtiendo a dataframe ego y añadimos las categorías
#que queremos que aparezcan
top_godown <- as.data.frame(egodown)[1:10, c("Description", "GeneRatio", "p.adjust", "Count")]
kable(top_godown, caption = "Top 10 términos GO-BP significativos en genes infraexpresados", digits = 4)
dotplot(egodown, showCategory = 10, font.size=6)

```